

INFATRACKVISION: HỆ THỐNG ĐO DAO ĐỘNG KHÔNG TIẾP XÚC BẰNG THỊ GIÁC MÁY TÍNH KẾT HỢP HỌC SÂU TRONG GIÁM SÁT SỨC KHỎE KẾT CẤU

INFATRACKVISION: A NON-CONTACT VIBRATION MEASUREMENT SYSTEM USING COMPUTER VISION COMBINED WITH DEEP LEARNING FOR STRUCTURAL HEALTH MONITORING

Abstract

Các phương pháp giám sát sức khỏe kết cấu truyền thống thường dựa trên cảm biến tiếp xúc, như gia tốc kế hoặc cảm biến biến dạng. Tuy nhiên, việc lắp đặt cảm biến trên công trình thực tế có thể làm tăng chi phí, yêu cầu hệ thống dây dẫn phức tạp và gặp khó khăn tại các vị trí khó tiếp cận. Nghiên cứu này trình bày hệ thống InfaTrackVision nhằm đo chuyển vị không tiếp xúc từ chuỗi ảnh camera và đánh giá khả năng sử dụng tín hiệu này cho chẩn đoán trạng thái kết cấu bằng học sâu. Hệ thống sử dụng camera công nghiệp, QR marker, theo dõi vùng quan tâm, đối sánh mẫu, nội suy sub-pixel và hiệu chuẩn pixel-milimét để trích xuất chuỗi chuyển vị theo thời gian. Thử nghiệm được thực hiện trên mô hình khung thép 3 tầng với tám trạng thái kết cấu khác nhau. Dữ liệu chuyển vị từ InfaTrackVision và dữ liệu gia tốc từ cảm biến PASCO được thu đồng thời trong cùng điều kiện thí nghiệm, sau đó được đưa vào ba kiến trúc học sâu chuỗi thời gian gồm 1D-CNN, CNN-LSTM và WaveNet. Kết quả cho thấy dữ liệu chuyển vị không tiếp xúc đạt hiệu năng phân loại cao, với accuracy lần lượt là 97.26%, 99.32% và 100.00% cho 1D-CNN, CNN-LSTM và WaveNet. Trên dữ liệu gia tốc PASCO, 1D-CNN và WaveNet đạt 100.00%, còn CNN-LSTM đạt 99.57%. Các kết

quả này cho thấy tín hiệu chuyển vị trích xuất từ camera có thể bảo toàn thông tin động lực học cần thiết cho chẩn đoán trạng thái kết cấu, đồng thời có tiềm năng bổ sung hoặc thay thế cảm biến tiếp xúc trong các kịch bản đo đạc phù hợp. Bộ dữ liệu thực nghiệm và mã nguồn của nghiên cứu được công bố công khai tại: <https://github.com/tritt13579/infartrackvision-shm>.

Keywords: Structural health monitoring; non-contact measurement; computer vision; contact sensors; time-series deep learning; 1D-CNN; CNN-LSTM; WaveNet.

1. Giới thiệu

Trong quá trình khai thác, các công trình xây dựng và công trình giao thông chịu tác động của tải trọng sử dụng, điều kiện môi trường và sự suy giảm tính chất vật liệu theo thời gian. Các yếu tố này có thể làm thay đổi đặc trưng động lực học của kết cấu, qua đó ảnh hưởng đến độ an toàn, khả năng làm việc và tuổi thọ khai thác. Giám sát sức khỏe kết cấu (Structural Health Monitoring – SHM) vì vậy được xem là một hướng tiếp cận quan trọng nhằm nhận diện và đánh giá trạng thái kết cấu dựa trên dữ liệu đo và phân tích định lượng [1].

Trong SHM dựa trên dao động, các cảm biến tiếp xúc như accelerometer hoặc đầu đo chuyển vị thường được sử dụng để thu nhận đáp ứng động lực học. Các hệ đo này có độ tin cậy cao nhưng vẫn tồn tại hạn chế khi triển khai trên công trình thực tế, bao gồm yêu cầu gắn cảm biến trực tiếp lên kết cấu, hệ thống dây tín hiệu, thiết bị thu nhận dữ liệu và công tác bảo trì. Tại các vị trí cao, xa hoặc nguy hiểm, việc lắp đặt cảm biến trở nên khó khăn; đối với mô hình thí nghiệm nhỏ, khối lượng cảm biến còn có thể ảnh hưởng đến đáp ứng dao động của hệ.

Thị giác máy tính cung cấp một hướng đo không tiếp xúc bằng cách trích xuất chuyển vị từ chuỗi ảnh hoặc video. Camera ghi nhận sự thay đổi vị trí của mục tiêu quan sát trên mặt phẳng ảnh, sau đó thuật toán xử lý ảnh chuyển đổi tọa độ ảnh thành chuỗi chuyển vị theo thời gian. Các nghiên cứu tổng quan cho thấy đo chuyển vị bằng machine vision có nhiều ưu điểm như giảm yêu cầu lắp đặt cảm biến, tăng tính linh hoạt và mở rộng khả năng quan sát theo không gian [2, 3]. Tuy nhiên, chất lượng dữ liệu thị giác phụ thuộc vào độ phân giải camera, tốc độ

khung hình, điều kiện chiếu sáng, marker, hiệu chuẩn và thuật toán tracking. Đối với dao động biên độ nhỏ, tinh chỉnh tọa độ ở mức sub-pixel đóng vai trò quan trọng trong việc giảm sai số lượng tử hóa và nâng cao chất lượng tín hiệu [4].

Bên cạnh nguồn đo, hiệu quả chẩn đoán trạng thái kết cấu còn phụ thuộc vào phương pháp khai thác dữ liệu dao động. Các phương pháp truyền thống thường dựa vào đặc trưng tần số, dạng dao động hoặc đặc trưng thống kê; hiệu quả của chúng phụ thuộc nhiều vào tiền xử lý và kinh nghiệm trích chọn đặc trưng [5]. Học sâu chuỗi thời gian cho phép mô hình học trực tiếp đặc trưng từ tín hiệu nhiều kênh và đã cho thấy tiềm năng trong SHM [6, 7]. Trong nghiên cứu này, ba kiến trúc gồm 1D-CNN, CNN-LSTM và WaveNet được sử dụng để đánh giá dữ liệu chuyển vị từ camera và dữ liệu gia tốc tiếp xúc trong cùng một bài toán phân loại.

Khoảng trống chính được đặt ra là liệu tín hiệu chuyển vị không tiếp xúc trích xuất từ camera có đủ độ tin cậy để làm đầu vào cho các mô hình học sâu hay không. Để trả lời câu hỏi này, nghiên cứu xây dựng hệ đo InfaTrackVision và thiết lập thí nghiệm đối chứng song song trên mô hình khung thép 3 tầng, trong đó dữ liệu chuyển vị camera và dữ liệu gia tốc PASCO được thu trong cùng điều kiện kích thích, cùng trạng thái kết cấu và cùng quy trình học sâu.

Các đóng góp chính của nghiên cứu gồm: (i) phát triển hệ đo chuyển vị không tiếp xúc InfaTrackVision dựa trên camera công nghiệp, QR marker, template matching và nội suy sub-pixel; (ii) thiết lập bộ dữ liệu đối chứng song song giữa chuyển vị thị giác máy tính và gia tốc PASCO trên mô hình khung thép 3 tầng với tám trạng thái; và (iii) đánh giá ba kiến trúc học sâu chuỗi thời gian trên hai nguồn dữ liệu nhằm xác định mức độ suy giảm hoặc tương đương về hiệu năng chẩn đoán khi sử dụng nguồn đo không tiếp xúc.

2. Hệ thống InfaTrackVision và cơ sở đo chuyển vị không tiếp xúc

2.1. Kiến trúc hệ thống

InfaTrackVision được xây dựng để thu nhận chuyển vị của kết cấu từ chuỗi ảnh camera theo hướng không tiếp xúc. Hệ thống gồm ba thành phần chính: phần

cứng thu ảnh, phần mềm xử lý ảnh và cơ chế lưu trữ dữ liệu đo. Phần cứng ghi nhận chuyển động của marker gắn trên kết cấu; phần mềm lựa chọn ROI, theo dõi vị trí ROI qua từng frame, tính chuyển vị theo thời gian và xuất dữ liệu; cơ chế lưu trữ bảo đảm dữ liệu có thể được sử dụng cho hậu xử lý và huấn luyện mô hình học sâu.

Bảng 1. Cấu hình phần cứng chính của hệ thống InfaTrackVision.

Thành phần	Thông số
Camera	Basler acA2040-90um
Độ phân giải ảnh	2048×2048 pixel
Kích thước pixel	$5.5 \mu m \times 5.5 \mu m$
Tốc độ khung hình danh định	90 fps
Khoảng cách camera đến kết cấu	Khoảng 1 m
Marker	QR marker kích thước 23 mm
Số ROI theo dõi	3 ROI



Hình 1. Camera Basler acA2040-90um sử dụng trong hệ đo InfaTrackVision.

Luồng xử lý của InfaTrackVision gồm các bước chính: nhận frame từ camera hoặc video, xác định ROI ban đầu, cắt template tham chiếu, theo dõi template trong các frame tiếp theo, tinh chỉnh vị trí bằng sub-pixel, tính chuyển vị, hiển thị đồ thị và lưu dữ liệu đo.



Hình 2. Luồng xử lý chính từ frame ảnh đến chuyển vị theo thời gian.

2.2. Đo chuyển vị từ chuỗi ảnh

Trong hệ tọa độ ảnh, ROI tại frame ban đầu được mô tả bởi hình chữ nhật

$$\text{ROI} = (x_1, y_1, x_2, y_2),$$

với tâm ban đầu

$$x_0 = \frac{x_1 + x_2}{2}, \quad y_0 = \frac{y_1 + y_2}{2}.$$

Tại thời điểm t , nếu thuật toán tracking xác định được tâm ROI là $P(t) = (x(t), y(t))$, chuyển vị ảnh theo hai phương được tính bởi

$$dx(t) = x(t) - x_0, \quad dy(t) = y(t) - y_0.$$

Với nhiều ROI, phép tính được lặp lại cho từng marker. Trong thí nghiệm khung thép 3 tầng, ba QR marker tương ứng với ba chuỗi chuyển vị đại diện cho đáp ứng của ba tầng.

2.3. Template matching và tính chỉnh sub-pixel

Sau khi ROI được xác định ở frame đầu tiên, vùng ảnh bên trong ROI được cắt làm template tham chiếu. Trong các frame tiếp theo, template matching tìm vị trí có mức tương đồng lớn nhất giữa template và vùng tìm kiếm. Nếu $R(x, y)$ là ma trận tương quan, vị trí khớp tốt nhất được xác định bởi


$$(x^*, y^*) = \arg \max_{(x, y)} R(x, y).$$

Độ tin cậy của phép đo được xác định từ giá trị tương quan lớn nhất:

$$c = \max_{(x, y)} R(x, y).$$

Trong cấu hình hiện tại, các kết quả có $c > 0.65$ được xem là đủ tin cậy cho tracking.

Do vị trí cực đại của template matching thường ở cấp pixel nguyên,



Hình 3. Minh họa quy trình khớp ảnh mẫu để xác định vị trí ROI.

InfaTrackVision sử dụng nội suy bậc hai trên lân cận 3×3 quanh đỉnh tương quan để tinh chỉnh tọa độ ở cấp sub-pixel. Bề mặt tương quan cục bộ được xấp xỉ bởi

$$S(x, y) = ax^2 + bxy + cy^2 + dx + ey + f.$$

Vị trí cực trị của bề mặt này được xác định bằng điều kiện gradient bằng 0. Từ đó, offset sub-pixel tương đối so với đỉnh pixel nguyên được tính và cộng vào tọa độ ROI. Bước này giúp giảm sai số lượng tử hóa và làm chuỗi chuyển vị mịn hơn, phù hợp hơn cho phân tích dao động và huấn luyện mô hình học sâu.

3. Mô hình học sâu cho chẩn đoán trạng thái kết cấu

Dữ liệu chuyển vị camera và dữ liệu gia tốc PASCO đều được biểu diễn dưới dạng chuỗi thời gian nhiều kênh. Với một mẫu sau khi cắt cửa sổ, tín hiệu đầu vào được viết dưới dạng

$$X \in \mathbb{R}^{C \times T},$$

trong đó C là số kênh tín hiệu và T là độ dài cửa sổ thời gian. Trong thí nghiệm khung thép 3 tầng, $C = 3$, tương ứng với ba tầng của kết cấu. Bài toán chẩn đoán trạng thái được phát biểu dưới dạng phân loại có giám sát:

$$f_{\theta}(X) \rightarrow y,$$

với y là nhãn trạng thái kết cấu.

Trước khi đưa vào mô hình, tín hiệu được chuẩn hóa theo z-score trong từng cửa sổ:

$$\hat{x}_{n,c}^{(i)} = \frac{x_{n,c}^{(i)} - \mu_c^{(i)}}{\sigma_c^{(i)} + \varepsilon}.$$

Cách chuẩn hóa này giúp mô hình tập trung vào dạng dao động và quan hệ tương đối giữa các kênh thay vì bị chi phối bởi khác biệt biên độ tuyệt đối giữa dữ liệu chuyển vị và dữ liệu gia tốc.

Ba kiến trúc học sâu được khảo sát gồm 1D-CNN, CNN-LSTM và WaveNet. Các mô hình đều nhận đầu vào là cửa sổ tín hiệu ba kênh, sau đó trích xuất đặc trưng theo trục thời gian và đưa đặc trưng cuối cùng vào lớp phân loại tám trạng thái kết cấu.


3.1. Cấu trúc mô hình 1D-CNN

Mô hình 1D-CNN được sử dụng như kiến trúc nền để khai thác đặc trưng cục bộ của tín hiệu dao động [8, 9]. Đầu vào $X \in \mathbb{R}^{C \times T}$ trước hết đi qua bốn lớp tích chập một chiều với số kênh lần lượt là 8, 16, 32 và 64. Các kernel có kích thước giảm dần 51, 21, 11 và 7 nhằm kết hợp khả năng quan sát dạng sóng trên các khoảng thời gian khác nhau. Stride bằng 2 được dùng trong các lớp tích chập để giảm dần chiều dài chuỗi, đồng thời mở rộng trường tiếp nhận hiệu dụng của các đặc trưng ở lớp sâu hơn.

Sau mỗi lớp tích chập, hàm kích hoạt phi tuyến được sử dụng để học các mẫu dao động đặc trưng cho từng trạng thái. Đặc trưng sau khối tích chập được làm phẳng và đưa qua hai lớp fully connected có 128 nút trước khi đi tới lớp đầu ra. Với cấu trúc này, 1D-CNN chủ yếu khai thác các mẫu cục bộ như thay đổi biên độ, dạng sóng ngắn hạn và quan hệ giữa ba kênh đo trong từng cửa sổ tín hiệu.

3.2. Cấu trúc mô hình CNN-LSTM

Mô hình CNN-LSTM kết hợp khả năng trích xuất đặc trưng cục bộ của CNN với khả năng mô hình hóa quan hệ tuần tự của LSTM [10, 11, 12]. Trong kiến trúc



Hình 4. Sơ đồ khái quát của mô hình 1D-CNN sử dụng cho dữ liệu dao động nhiều kênh.


này, tín hiệu đầu vào trước hết đi qua ba lớp Conv1D với số kênh 8, 16 và 32, sử dụng kernel lần lượt là 21, 11 và 7. Khối CNN đóng vai trò biến đổi chuỗi dao động ban đầu thành chuỗi đặc trưng có mức trừu tượng cao hơn, đồng thời giảm chiều dài chuỗi bằng stride 2.

Chuỗi đặc trưng thu được từ khối CNN sau đó được đưa vào một lớp LSTM với 128 trạng thái ẩn. LSTM tổng hợp thông tin theo chiều thời gian và giữ lại các đặc trưng liên quan đến diễn biến dao động trong toàn bộ cửa sổ. Vector biểu diễn cuối cùng được đưa qua lớp fully connected 128 nút và lớp phân loại. Cấu trúc này phù hợp với trường hợp sự khác biệt giữa các trạng thái không chỉ nằm ở mẫu cục bộ, mà còn liên quan đến trình tự biến thiên và quan hệ pha giữa các tầng.

3.3. Cấu trúc mô hình WaveNet


WaveNet được sử dụng để khai thác phụ thuộc thời gian ở nhiều thang khác nhau thông qua tích chập nhân quả giãn nở [13]. Mô hình gồm một khối residual với bốn lớp tích chập giãn nở, trong đó hệ số giãn nở lần lượt là 1, 2, 4 và 8. Với kernel kích thước 2, cách bố trí dilation này cho phép trường tiếp nhận tăng nhanh theo chiều sâu mạng mà không làm tăng đáng kể số tham số.

Trong mỗi residual layer, tín hiệu đi qua nhánh tích chập có cơ chế gated



Hình 5. Sơ đồ mô hình CNN-LSTM: khối CNN trích xuất đặc trưng cục bộ, sau đó LSTM mô hình hóa quan hệ tuần tự.

activation để điều tiết lượng thông tin được truyền qua. Đầu ra của mỗi lớp được kết hợp bằng residual connection nhằm ổn định huấn luyện, đồng thời skip connection đưa đặc trưng ở nhiều mức trường tiếp nhận đến phần tổng hợp cuối. Sau bước downsample và tổng hợp đặc trưng, mô hình tạo vector phân loại cho tám trạng thái kết cấu. Nhờ cấu trúc này, WaveNet có khả năng khai thác đồng thời dao động ngắn hạn và phụ thuộc dài hơn trong cửa sổ tín hiệu.



Hình 6. Sơ đồ tích chập nhân quả giãn nở trong WaveNet, giúp mở rộng trường tiếp nhận theo nhiều thang thời gian.

4. Thiết lập thực nghiệm

4.1. Mô hình khung thép 3 tầng

Thiết lập thực nghiệm sử dụng mô hình khung thép ba tầng nhằm tạo ra môi trường đối chứng có kiểm soát giữa dữ liệu không tiếp xúc từ hệ thị giác máy tính và dữ liệu tiếp xúc từ cảm biến gia tốc. Mô hình có ba bậc tự do chính theo

Bảng 2. Cấu hình chính của các mô hình học sâu trong thực nghiệm.

Thành phần	1D-CNN	CNN-LSTM	WaveNet
Tích chập	Conv1D: 8–16–32–64	Conv1D: 8–16–32	Dilated residual Conv1D
Kernel	51–21–11–7	21–11–7	2
Downsample	Stride 2	Stride 2	Downsample 4
Khối tuần tự	–	LSTM 128	4 residual layers
Dilation	–	–	1–2–4–8
Phân loại	FC 128–128	FC 128	Skip/residual aggregation

phương dao động ngang; mỗi tầng được xem như một vị trí đo đại diện cho đáp ứng động học của hệ.



Hình 7. Mô hình khung thép 3 tầng và bố trí cảm biến PASCO trên các tầng.

Trên mô hình khung thép, cảm biến gia tốc PASCO được gắn tại các tầng để thu nhận tín hiệu tiếp xúc, trong khi camera công nghiệp của hệ InfaTrackVision được đặt bên ngoài kết cấu để quan sát chuyển động của các điểm đo tương ứng. Dao động của khung được tạo bởi máy kích thích PASCO và nguồn kích thích được giữ nhất quán giữa các trạng thái.



Hình 8. Toàn cảnh bố trí thí nghiệm đo dao động trên khung thép 3 tầng.

4.2. Kích bản trạng thái và dữ liệu đo

Các trạng thái kết cấu được mô phỏng bằng cách thay đổi phân bố khối lượng tại các tầng của khung. Thay đổi khối lượng làm biến đổi đặc trưng động lực học của hệ, qua đó tạo ra các lớp trạng thái có thể được nhận diện từ tín hiệu dao động.

Bảng 3. Các trạng thái kết cấu của mô hình khung thép 3 tầng.

Nhãn	Mô tả trạng thái
No damage	Không gắn khối lượng bổ sung
a	Hư hỏng giả lập tại tầng 1
b	Hư hỏng giả lập tại tầng 2
c	Hư hỏng giả lập tại tầng 3
ab	Hư hỏng giả lập tại tầng 1 và tầng 2
ac	Hư hỏng giả lập tại tầng 1 và tầng 3
bc	Hư hỏng giả lập tại tầng 2 và tầng 3
abc	Hư hỏng giả lập tại cả ba tầng

Dữ liệu thị giác máy tính được trích xuất từ chuỗi ảnh thu bởi camera công nghiệp. Với mỗi tầng, hệ InfaTrackVision theo dõi ROI tương ứng và chuyển đổi vị trí tâm mục tiêu thành chuỗi chuyển vị. Sau hiệu chuẩn pixel–milimét, một mẫu đo của hệ ba tầng được biểu diễn dưới dạng

$$X_{\text{cam}}(t) = \{d_1(t), d_2(t), d_3(t)\}.$$

Dữ liệu tiếp xúc được thu bằng cảm biến gia tốc PASCO gắn trên ba tầng:

$$X_{\text{acc}}(t) = \{a_1(t), a_2(t), a_3(t)\}.$$

Hai nguồn dữ liệu được xử lý theo cùng một quy trình chia cửa sổ, chuẩn hóa và huấn luyện, nhờ đó kết quả phân loại phản ánh trực tiếp mức chênh lệch giữa nguồn đo không tiếp xúc và nguồn đo tiếp xúc.

Tín hiệu liên tục được chia thành các cửa sổ không chồng lấn có chiều dài $W = 1024$. Với mỗi trạng thái, các tệp dữ liệu được chia thành tập huấn luyện, validation và kiểm tra theo từng tệp đo để tránh trộn dữ liệu cùng bản ghi giữa các tập. Các mô hình được huấn luyện với batch size 32, tối đa 100 epoch, learning rate ban đầu 10^{-3} , hàm mất mát cross-entropy và bộ tối ưu Adam. Checkpoint được chọn theo accuracy cao nhất trên tập validation.

5. Kết quả và thảo luận



5.1. Kết quả trên dữ liệu chuyển vị từ InfaTrackVision

Dữ liệu chuyển vị gồm ba kênh tương ứng với ba tầng của khung. Sau bước chia cửa sổ, tập dữ liệu gồm 434 mẫu huấn luyện, 145 mẫu validation và 146 mẫu kiểm tra. Kết quả phân loại được trình bày trong Bảng 4.



Bảng 4. Kết quả phân loại trên dữ liệu chuyển vị đo bằng thị giác máy tính.

Mô hình	Accuracy (%)	Precision (%)	Recall (%)	F1-score (%)
1D-CNN	97.26	97.47	97.26	97.26
CNN-LSTM	99.32	99.35	99.32	99.31
WaveNet	100.00	100.00	100.00	100.00



Trên dữ liệu chuyển vị, cả ba mô hình đều đạt hiệu năng cao. 1D-CNN có bốn mẫu phân loại sai trên tập kiểm tra, CNN-LSTM giảm số lỗi xuống còn một mẫu, trong khi WaveNet phân loại đúng toàn bộ 146 mẫu kiểm tra. Kết quả này cho thấy tín hiệu chuyển vị không tiếp xúc chứa đủ thông tin động lực học để phân biệt tám trạng thái kết cấu khi được xử lý bằng mô hình có khả năng khai thác phụ thuộc thời gian dài.



Hình 9. Đường cong học và ma trận nhầm lẫn của 1D-CNN trên dữ liệu chuyển vị.



Hình 10. Đường cong học và ma trận nhầm lẫn của CNN-LSTM trên dữ liệu chuyển vị.



Hình 11. Đường cong học và ma trận nhầm lẫn của WaveNet trên dữ liệu chuyển vị.


5.2. Kết quả trên dữ liệu gia tốc PASCO và đối chứng hai nguồn đo

Dữ liệu gia tốc PASCO cũng gồm ba kênh tương ứng với ba tầng của khung. Sau bước chia cửa sổ, tập dữ liệu gồm 696 mẫu huấn luyện, 233 mẫu validation và 233 mẫu kiểm tra. Kết quả phân loại được trình bày trong Bảng 5.

Bảng 5. Kết quả phân loại trên dữ liệu gia tốc đo bằng cảm biến PASCO.



Mô hình	Accuracy (%)	Precision (%)	Recall (%)	F1-score (%)
1D-CNN	100.00	100.00	100.00	100.00
CNN-LSTM	99.57	99.59	99.57	99.57
WaveNet	100.00	100.00	100.00	100.00

Trên dữ liệu gia tốc PASCO, 1D-CNN và WaveNet đạt 100.00% trên toàn bộ chỉ số; CNN-LSTM đạt accuracy 99.57% với một mẫu ac bị nhầm sang c . Khi so sánh với dữ liệu chuyển vị từ camera, mức chênh lệch là nhỏ: 1D-CNN giảm từ 100.00% xuống 97.26%, CNN-LSTM thay đổi từ 99.57% xuống 99.32%, còn WaveNet giữ nguyên mức 100.00%. Điều này cho thấy dữ liệu chuyển vị từ InfaTrackVision không làm suy giảm đáng kể hiệu năng chẩn đoán trong thiết lập thí nghiệm hiện tại.



Hình 12. Đường cong học và ma trận nhầm lẫn của 1D-CNN trên dữ liệu gia tốc PASCO.

Kết quả đối chứng cho thấy chất lượng tín hiệu chuyển vị từ InfaTrackVision đủ tốt để sử dụng trực tiếp cho học sâu. Nếu nguồn đo camera gây mất thông tin động lực học nghiêm trọng, sự suy giảm hiệu năng sẽ xuất hiện đồng thời ở cả ba kiến trúc. Tuy nhiên, cả ba mô hình đều đạt accuracy trên 97%, trong đó WaveNet đạt 100% trên cả dữ liệu chuyển vị và dữ liệu gia tốc. Điều này cho thấy quy trình



Hình 13. Đường cong học và ma trận nhầm lẫn của CNN-LSTM trên dữ liệu gia tốc PASCO.

theo dõi ROI, template matching, nội suy sub-pixel và hiệu chuẩn pixel–milimét đã bảo toàn được đặc trưng dao động cần thiết cho phân loại trạng thái kết cấu.

Từ góc độ lựa chọn mô hình, 1D-CNN là phương án đơn giản và hiệu quả khi dữ liệu có ranh giới lớp rõ. CNN-LSTM phù hợp khi tín hiệu cần bổ sung khả năng mô hình hóa trình tự sau bước trích xuất đặc trưng cục bộ. WaveNet là kiến trúc ổn định nhất trong nhóm mô hình khảo sát, đặc biệt khi các trạng thái có đáp ứng gần nhau và cần khai thác phụ thuộc thời gian ở phạm vi rộng hơn.

6. Kết luận

Nghiên cứu đã xây dựng và đánh giá hệ đo chuyển vị không tiếp xúc InfaTrackVision kết hợp với các mô hình học sâu chuỗi thời gian cho bài toán chẩn đoán trạng thái kết cấu. Hệ thống sử dụng quy trình theo dõi ROI, template matching, nội suy sub-pixel và hiệu chuẩn pixel–milimét để trích xuất tín hiệu chuyển vị từ chuỗi ảnh. Trên mô hình khung thép 3 tầng, dữ liệu chuyển vị từ camera và dữ liệu gia tốc từ cảm biến PASCO được thu đồng thời trong cùng điều kiện thí nghiệm, cho phép đánh giá đối chứng trực tiếp giữa nguồn đo không tiếp xúc và nguồn đo tiếp xúc.

Kết quả thực nghiệm cho thấy dữ liệu chuyển vị từ InfaTrackVision có đủ chất lượng để sử dụng làm đầu vào cho các mô hình học sâu. Trên dữ liệu chuyển vị, 1D-CNN đạt accuracy 97.26%, CNN-LSTM đạt 99.32% và WaveNet đạt 100.00%. Trên dữ liệu gia tốc PASCO, 1D-CNN và WaveNet đạt 100.00%, trong khi CNN-

LSTM đạt 99.57%. Mức chênh lệch nhỏ giữa hai nguồn dữ liệu cho thấy quy trình xử lý ảnh, nội suy sub-pixel và hiệu chuẩn không gian đã bảo toàn được các đặc trưng dao động cần thiết cho phân loại trạng thái kết cấu.

Xét tổng thể, InfaTrackVision có tiềm năng trở thành nguồn dữ liệu không tiếp xúc đáng tin cậy cho SHM dựa trên học sâu, đặc biệt trong các trường hợp cần giảm can thiệp vật lý lên kết cấu và tăng tính linh hoạt của hệ quan trắc. Trong ba kiến trúc khảo sát, WaveNet cho hiệu năng ổn định nhất trên cả dữ liệu chuyển vị camera và dữ liệu gia tốc PASCO; 1D-CNN là phương án đơn giản nhưng hiệu quả; CNN-LSTM phù hợp khi cần kết hợp đặc trưng cục bộ với quan hệ tuần tự của tín hiệu dao động.

Tài liệu

- [1] C. R. Farrar and K. Worden, “An introduction to structural health monitoring,” *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 365, no. 1851, pp. 303–315, 2007.
- [2] Y. Xu and J. M. W. Brownjohn, “Review of machine-vision based methodologies for displacement measurement in civil structures,” *Journal of Civil Structural Health Monitoring*, vol. 8, no. 1, pp. 91–110, 2018.
- [3] J. M. W. Brownjohn, Y. Xu, and D. Hester, “Vision-based bridge deformation monitoring,” *Frontiers in Built Environment*, vol. 3, p. 23, 2017.
- [4] T. Liu, Y. Lei, and Y. Mao, “Computer vision-based structural displacement monitoring and modal identification with subpixel localization refinement,” *Advances in Civil Engineering*, vol. 2022, article 5444101, 2022, doi: 10.1155/2022/5444101.
- [5] H. Sohn, C. R. Farrar, F. M. Hemez, and J. J. Czarnecki, “A review of structural health monitoring literature: 1996–2001,” Los Alamos National Laboratory, 2002.
- [6] G. Toh and J. Park, “Review of vibration-based structural health monitoring using deep learning,” *Applied Sciences*, vol. 10, no. 5, p. 1680, 2020.

- [7] M. Azimi, A. D. Eslamlou, and G. Pekcan, “Data-driven structural health monitoring and damage detection through deep learning: State-of-the-art review,” *Sensors*, vol. 20, no. 10, p. 2778, 2020.
- [8] O. Abdeljaber, O. Avci, S. Kiranyaz, M. Gabbouj, and D. J. Inman, “Real-time vibration-based structural damage detection using one-dimensional convolutional neural networks,” *Journal of Sound and Vibration*, vol. 388, pp. 154–170, 2017.
- [9] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, “1D convolutional neural networks and applications: A survey,” *Mechanical Systems and Signal Processing*, vol. 151, p. 107398, 2021.
- [10] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [11] J. Donahue, L. A. Hendricks, S. Guadarrama, M. Rohrbach, S. Venugopalan, K. Saenko, and T. Darrell, “Long-term recurrent convolutional networks for visual recognition and description,” in *IEEE Conference on Computer Vision and Pattern Recognition*, 2015.
- [12] F. Karim, S. Majumdar, H. Darabi, and S. Chen, “LSTM fully convolutional networks for time series classification,” *IEEE Access*, vol. 6, pp. 1662–1669, 2018.
- [13] A. van den Oord, S. Dieleman, H. Zen, K. Simonyan, O. Vinyals, A. Graves, N. Kalchbrenner, A. Senior, and K. Kavukcuoglu, “WaveNet: A generative model for raw audio,” *arXiv*, 2016.